

# 如何处理非线性的分类问题

核函数

小胖



# 目录

## ONE 核函数的定义

优化运算

## TWO 常用的核函数


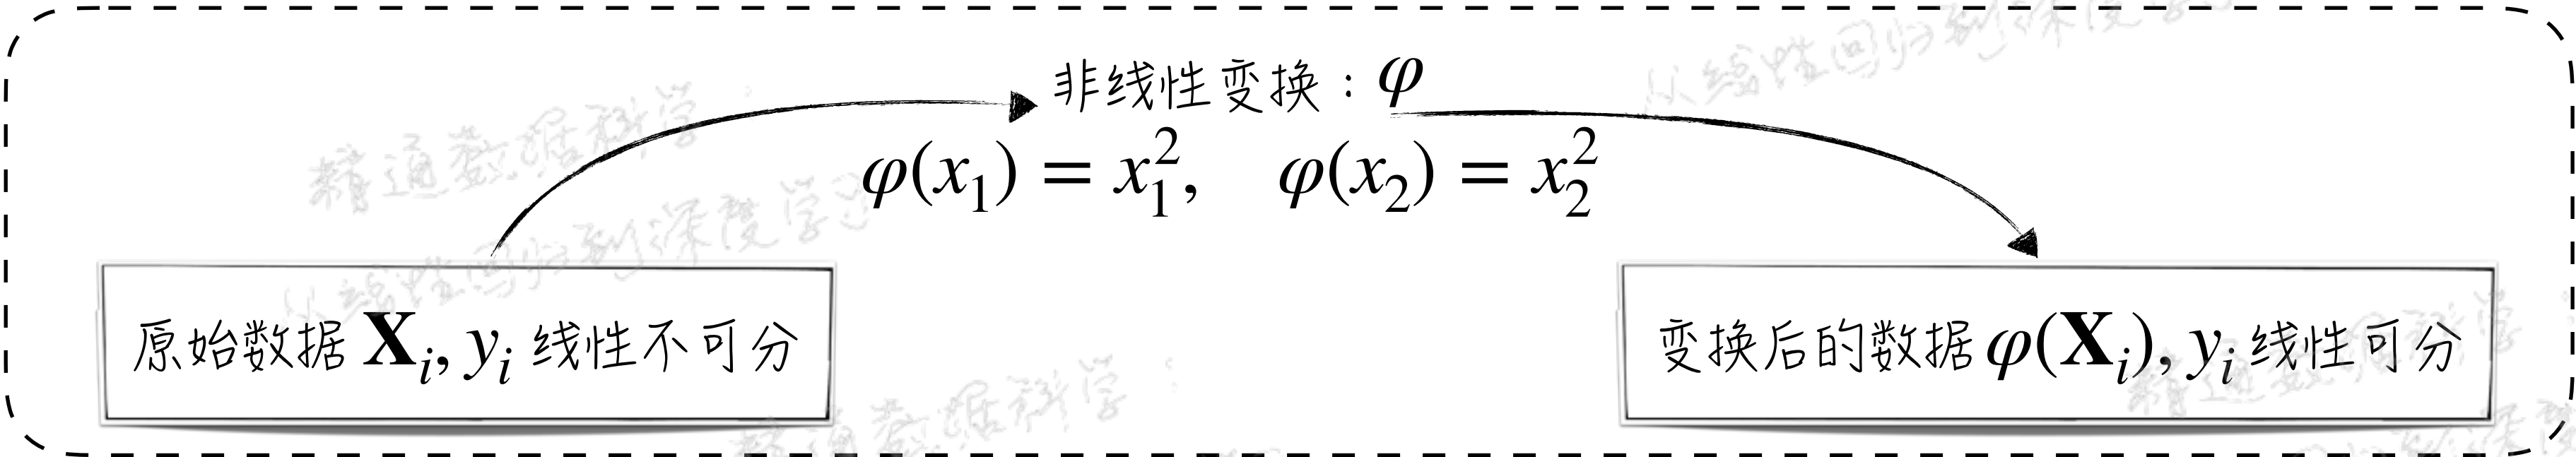
Gaussian、Laplacian、etc

## THREE Scale variant

线性变换不稳定

# 核函数的定义

空间变换



- 变换函数很难定义
- 运算复杂程度高

核函数解决的问题

# 核函数的定义

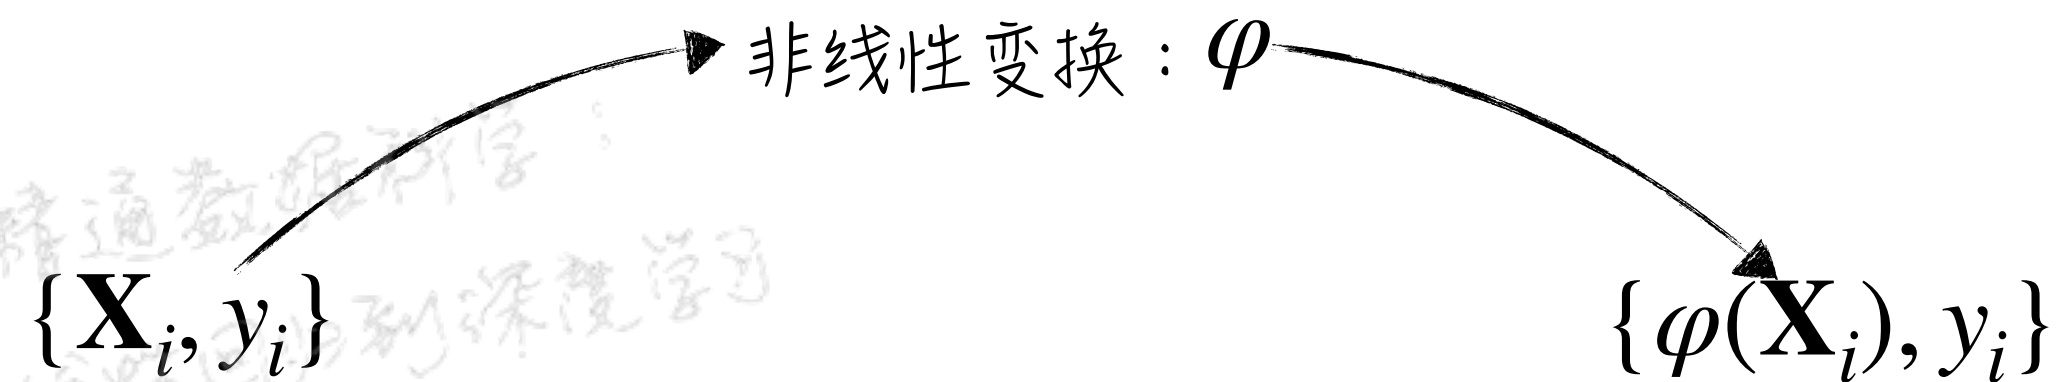
SVM的对偶问题

Dual problem

$$\begin{aligned} \max_{\alpha} \quad & \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} y_i y_j \alpha_i \alpha_j (\mathbf{X}_i \cdot \mathbf{X}_j) \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C \\ & \sum_i \alpha_i y_i = 0, \forall i \end{aligned}$$

$$\hat{y}_j = \text{sign}(\sum_i \hat{\alpha}_i y_i (\mathbf{X}_i \cdot \mathbf{X}_j) + \hat{c})$$

- SVM模型在训练和预测时，只会用到内积运算
- 我们只关心非线性变换后，“新数据”的内积



SVM只需要：  $\varphi(\mathbf{X}_i) \cdot \varphi(\mathbf{X}_j)$

$$K(\mathbf{X}_i, \mathbf{X}_j) = \varphi(\mathbf{X}_i) \cdot \varphi(\mathbf{X}_j)$$

这就是核函数



# 核函数的定义

一个例子

一个例子

$$K(\mathbf{X}_i, \mathbf{X}_j) = \varphi(\mathbf{X}_i) \cdot \varphi(\mathbf{X}_j)$$

$$\mathbf{X}_i = (x_{1,i}, x_{2,i})$$

$$\varphi(\mathbf{X}_i) \cdot \varphi(\mathbf{X}_j) = x_{1,i}^2 x_{1,j}^2 + x_{2,i}^2 x_{2,j}^2 + 2x_{1,i} x_{2,i} x_{1,j} x_{2,j} = K(\mathbf{X}_i, \mathbf{X}_j)$$

$$\varphi(\mathbf{X}_i) = (x_{1,i}^2, x_{2,i}^2, \sqrt{2}x_{1,i}x_{2,i})$$

$$\varphi(\mathbf{X}_i) \cdot \varphi(\mathbf{X}_j) = (x_{1,i}x_{1,j} + x_{2,i}x_{2,j})^2 = (\mathbf{X}_i \cdot \mathbf{X}_j)^2 = K(\mathbf{X}_i, \mathbf{X}_j)$$

起点

对于已知的空间变换  $\varphi(\mathbf{X}_i)$

优化计算过程, 减少模型运算量

在模型里使用某个核函数

不知不觉间完成了数据的空间转换

- 如何知道一个函数是核函数?
- 如何选择核函数?

# 目录

ONE

核函数的定义

优化计算

TWO

常用的核函数

Gaussian、Laplacian、etc

THREE

Scale variant

线性变换不稳定

# 常用的核函数

## 常用核函数

- 核函数的证明通常十分困难, 需要用到Mercer定理
- 数学家已经找到了一些对大多数场景都适用的常用核函数

### 常用核函数

Linear kernel :

$$K(\mathbf{X}_i, \mathbf{X}_j) = \mathbf{X}_i \cdot \mathbf{X}_j$$

没做任何空间变换, 对应着最经典的线性支持向量学习机

Polynomial kernel :

$$K(\mathbf{X}_i, \mathbf{X}_j) = (\text{gamma}(\mathbf{X}_i \cdot \mathbf{X}_j) + \text{coef0})^{\text{degree}}$$

Sigmoid kernel :

$$K(\mathbf{X}_i, \mathbf{X}_j) = \tanh(\text{gamma}(\mathbf{X}_i \cdot \mathbf{X}_j) + \text{coef0})$$

Laplacian kernel :

$$K(\mathbf{X}_i, \mathbf{X}_j) = \exp(-\text{gamma}\|\mathbf{X}_i - \mathbf{X}_j\|_1)$$

RBF kernel :

$$K(\mathbf{X}_i, \mathbf{X}_j) = \exp(-\text{gamma}\|\mathbf{X}_i - \mathbf{X}_j\|^2)$$

将数据映射到无限维空间

也称为Gaussian kernel, 是魔力十足的核函数

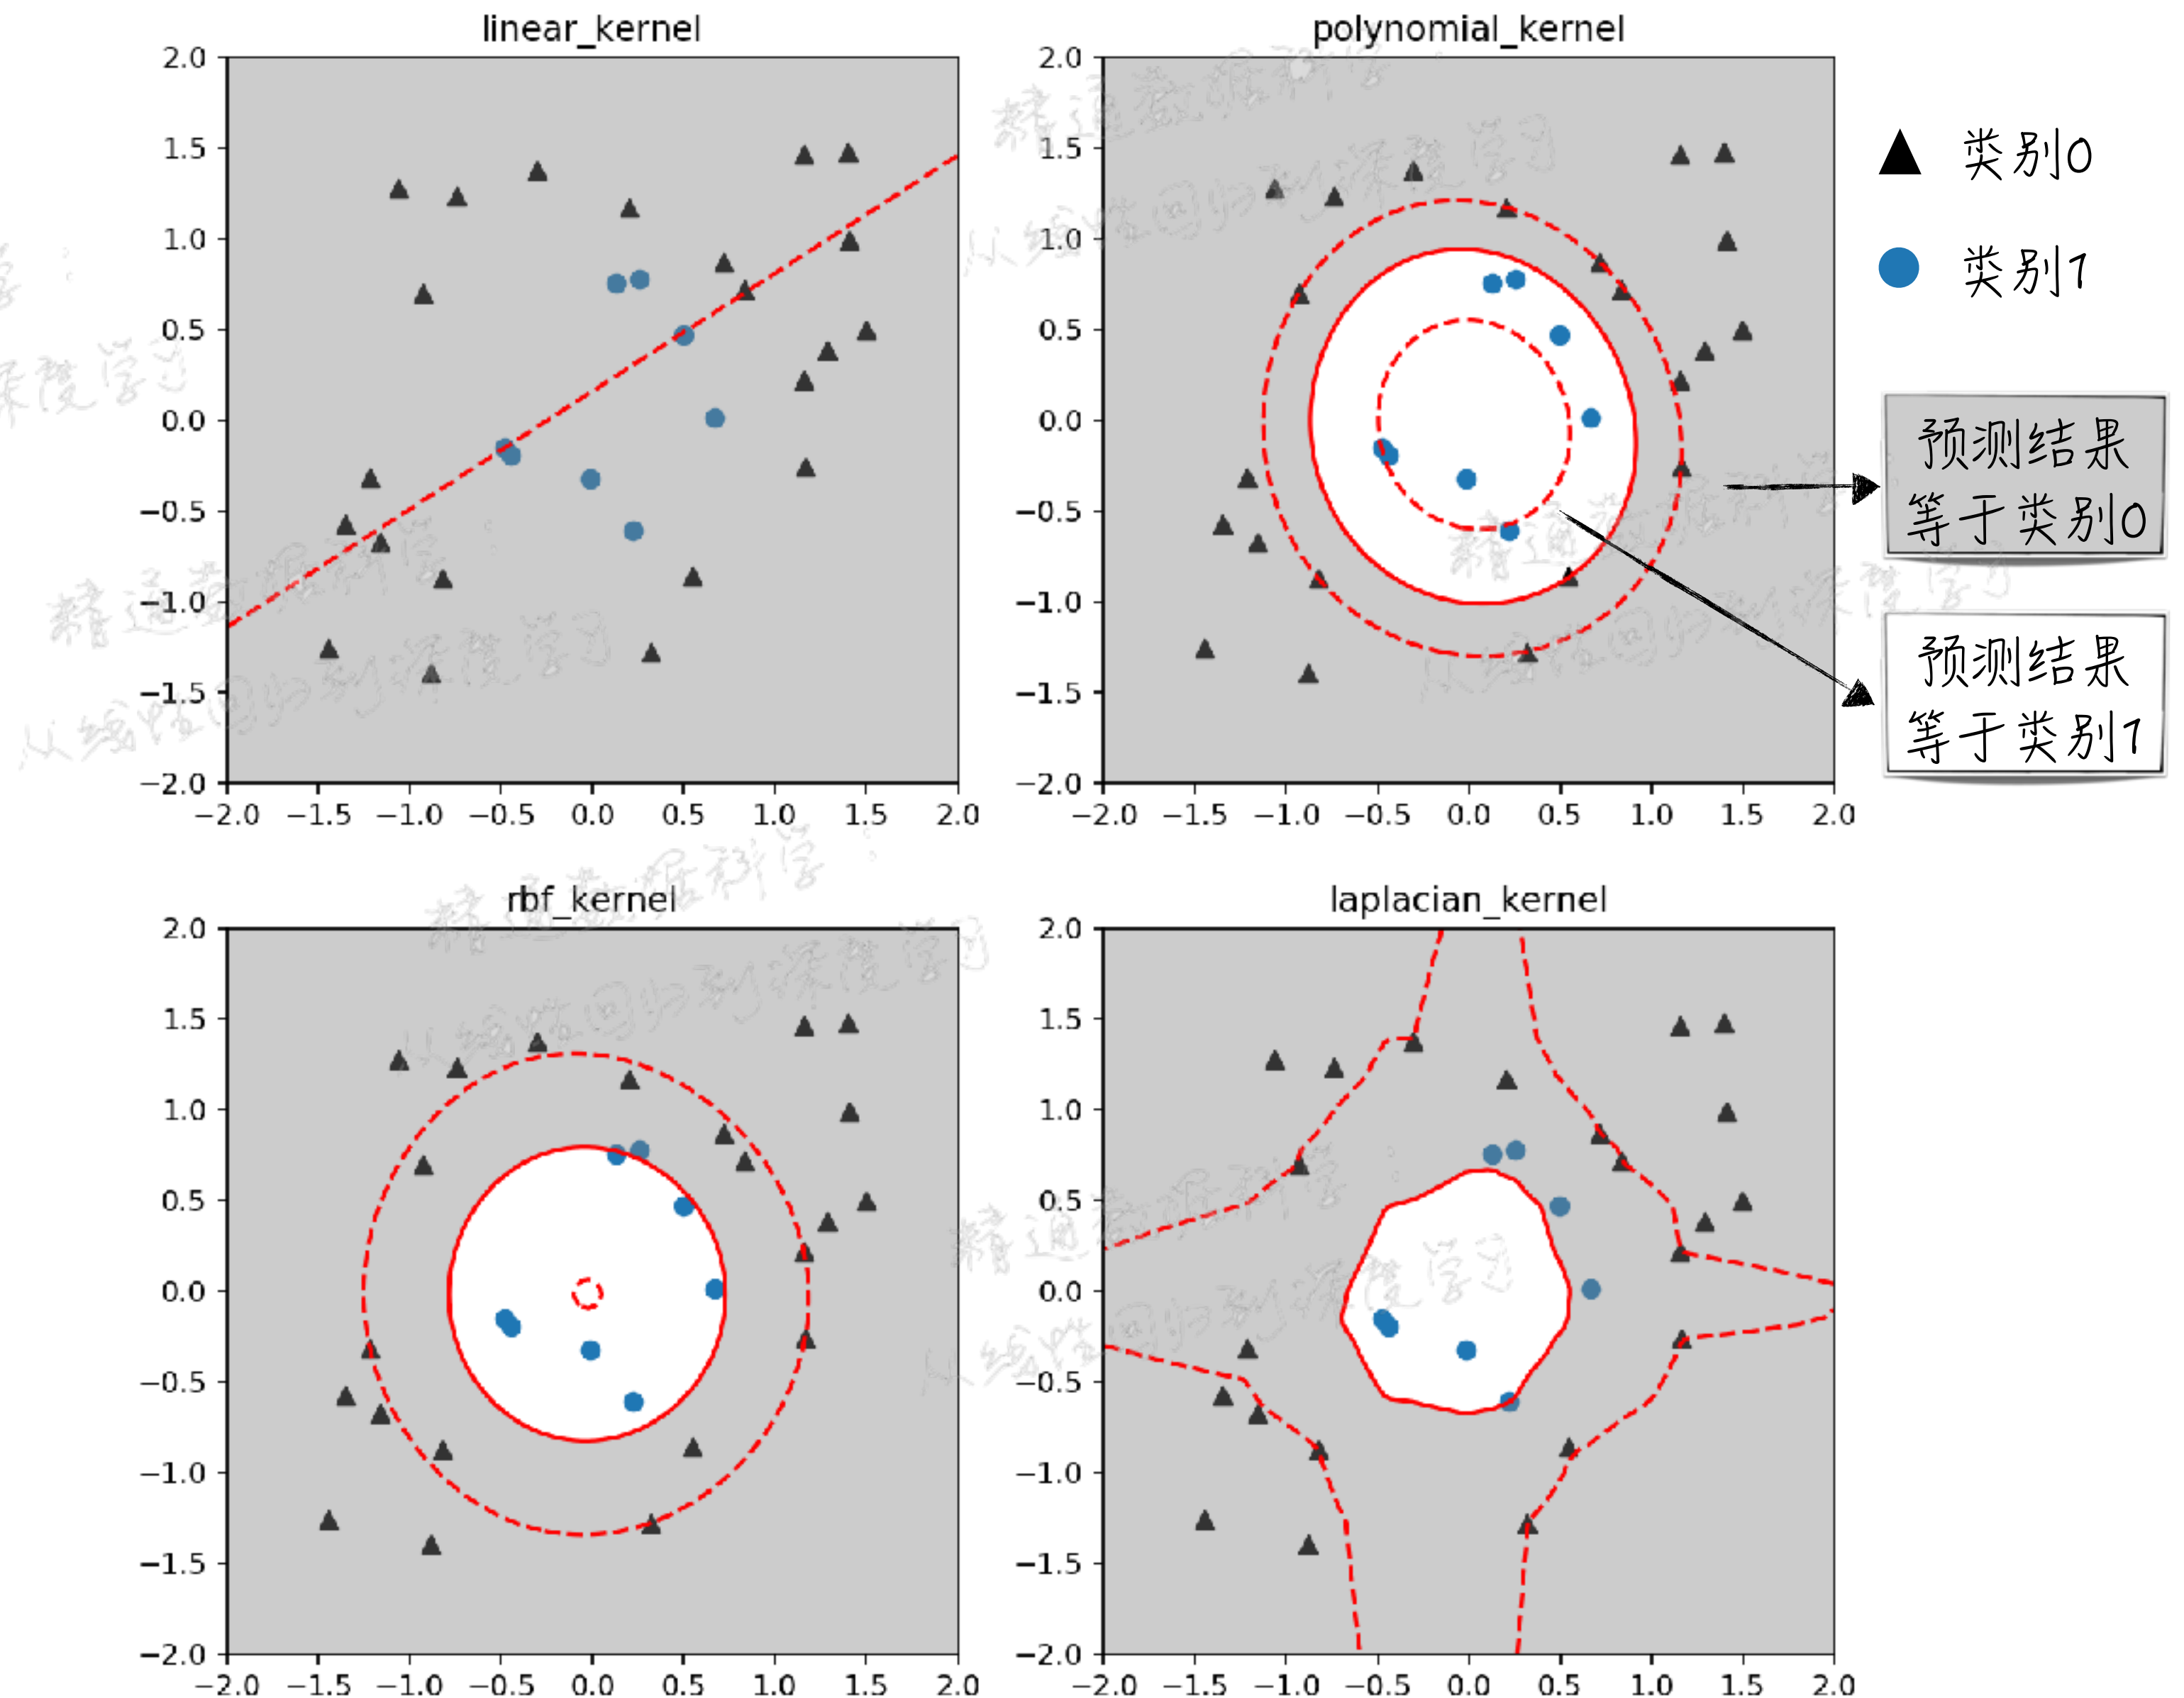


# 常用的核函数

效果示例

对于同一数据使用不同的核函数进行建模：

- 多项式核函数、高斯核函数、拉普拉斯核函数的效果都很好
- 高斯核函数和拉普拉斯核函数将数据映射到无限维空间





# 目录

ONE

核函数的定义

优化计算

TWO

常用的核函数

Gaussian、Laplacian、etc

THREE

Scale variant

线性变换不稳定

# Scale variant

线性变换不稳定

之前讨论的线性回归和逻辑回归对自变量的线性变换是稳定的:

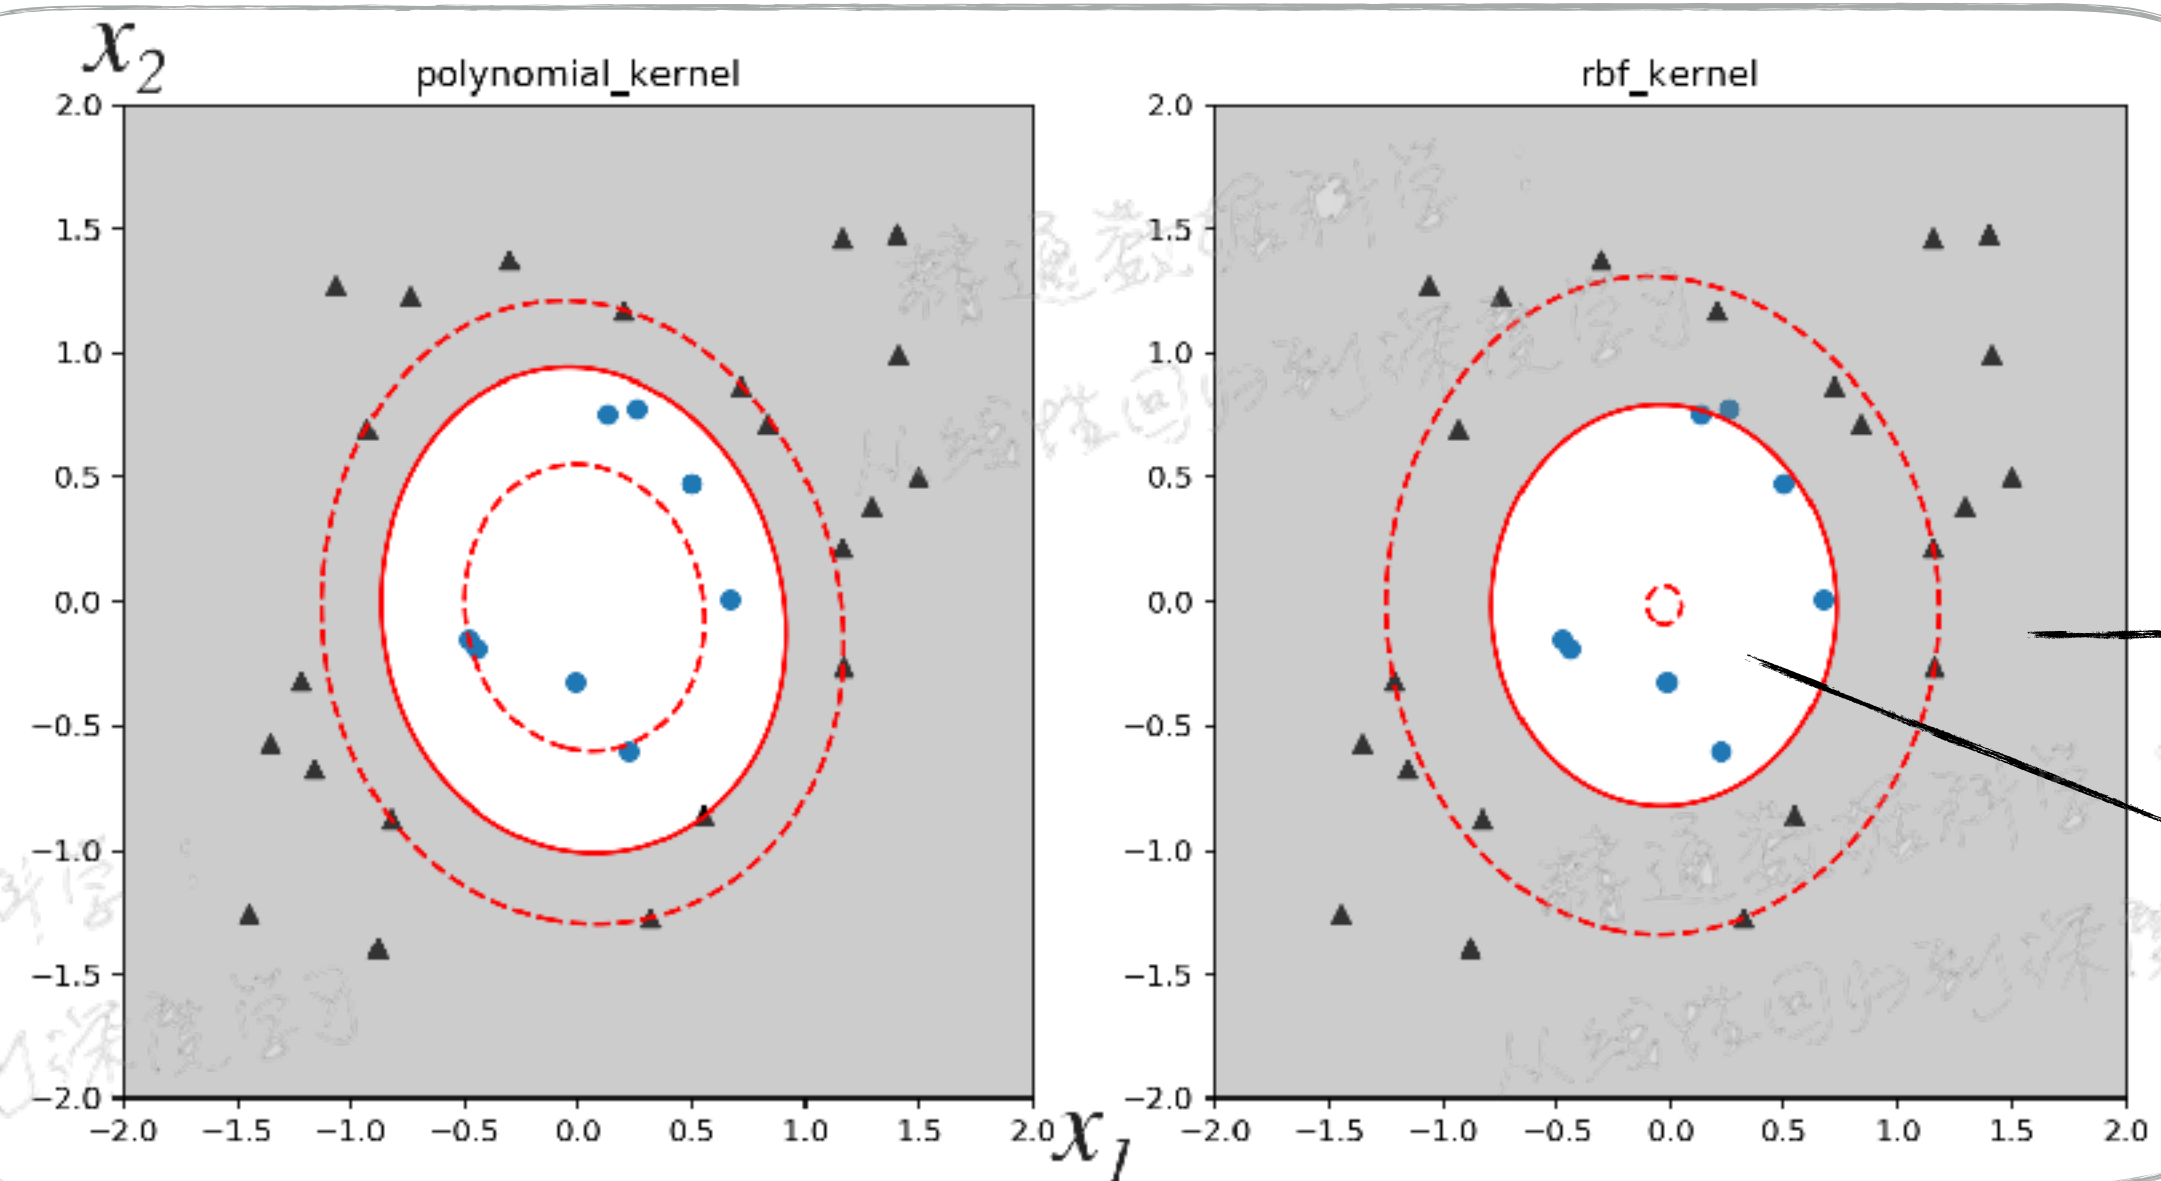
- 对自变量做线性变换（平移、伸缩）不影响模型结果；这被称为 Scale invariant

$$xx = ax + b$$

- 但SVM模型不是，它对自变量的线性变换不稳定

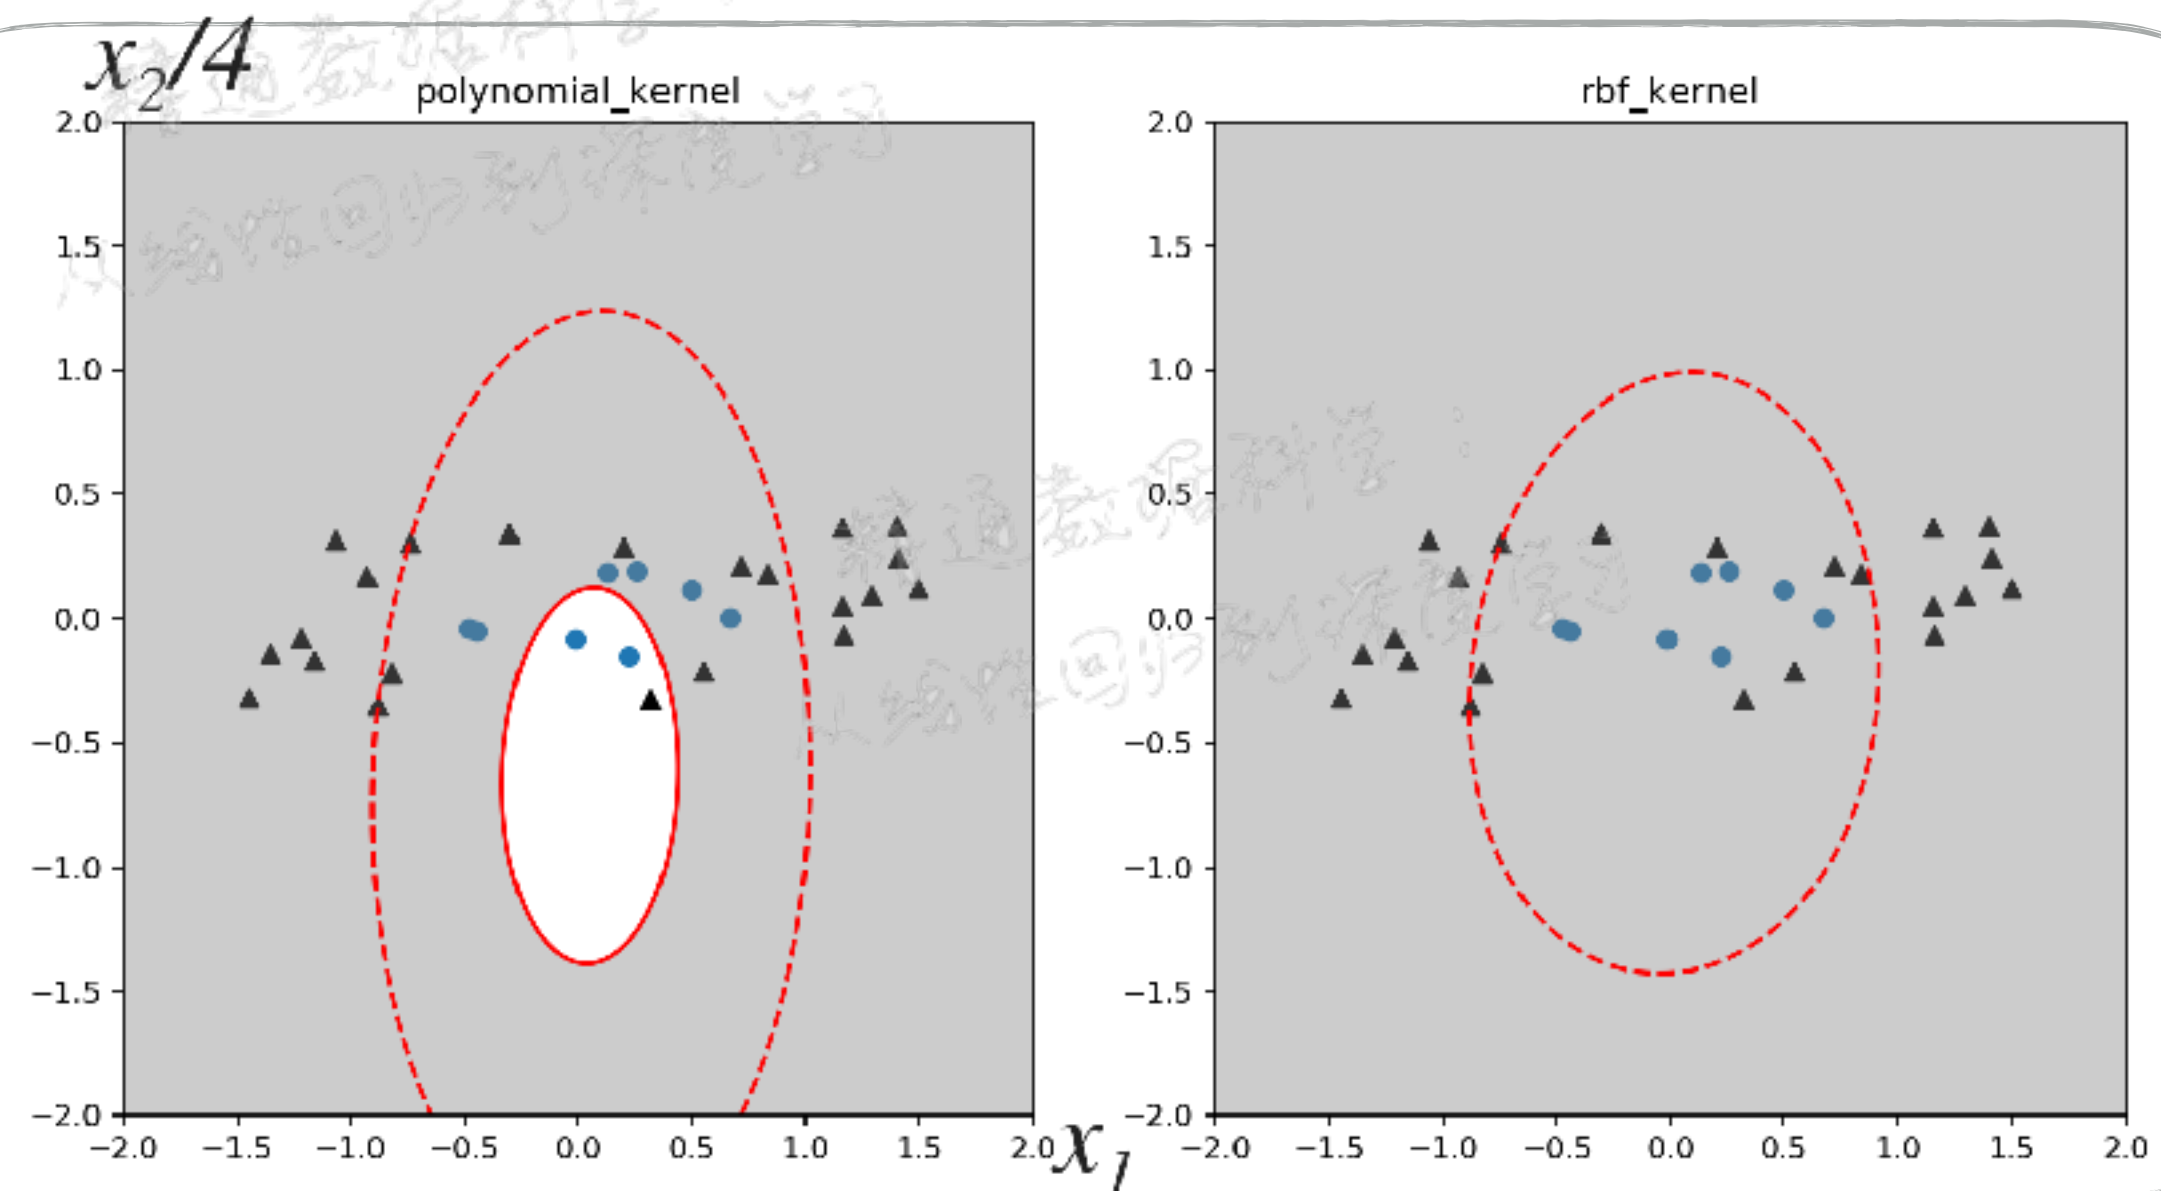
$x_1$ 和 $x_2$ 的变化  
幅度相似

1



线性变换  
 $x_2/4$

2





# Scale variant

数学原理

Dual problem

$$\begin{aligned} \max_{\alpha} \quad & \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} y_i y_j \alpha_i \alpha_j (\mathbf{X}_i \cdot \mathbf{X}_j) \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C \\ & \sum_i \alpha_i y_i = 0, \forall i \end{aligned}$$

$$\hat{y}_j = \text{sign}(\sum_i \hat{\alpha}_i y_i (\mathbf{X}_i \cdot \mathbf{X}_j) + \hat{c})$$

原始数据：

$$\mathbf{X}_i = (x_{1,i}, x_{2,i}) \quad \mathbf{X}_i \mathbf{X}_j = x_{1,i} x_{1,j} + x_{2,i} x_{2,j}$$

线性变换后：

$$\mathbf{X}_i = (x_{1,i}, 10x_{2,i}) \quad \mathbf{X}_i \mathbf{X}_j = x_{1,i} x_{1,j} + 100x_{2,i} x_{2,j}$$

变量的权重被扭曲，且模型无力修复

应对方案：变量归一化（各变量的变化幅度相当）

# THANK YOU

精通数据科学：  
从线性回归到深度学习